

# Einführung in die Computerlinguistik

## Syntax I

WS 2014/2015

Vera Demberg

# Morphologiesysteme: Grundaufgaben

- Flexionsmorphologie: Lemmatisierung/Stemming
  - *veranstalt+et, Veranstaltung+en*
- Ableitungs-/Derivationsmorphologie
  - *Veranstalt+ung, un+glaubwürdig*
- Komposita-Zerlegung
  - *Fach+veranstaltung, glaub+würdig*

# Morphologische Zerlegung: Ableitungen

Derivationsmorphologie ist in verschiedener Hinsicht unsystematisch. Beispiele:

- die *Lesung* bezeichnet den Akt des Vorlesens,
- die *Singung* ist unmöglich
- die *Vorlesung* gibt es, bezeichnet aber nicht den Akt des Vorlesens,
- die *Schreibung* nicht den Akt des Schreibens

Viele Ableitungspräfixe und -suffixe sind semiproduktiv.

Viele Ableitungen sind semantisch "nicht transparent": Sie haben eine konventionelle, lexikalisierte Bedeutung, die mit der Bedeutung des Stammworts nicht in systematischer Beziehung steht.

# Morphologische Zerlegung: Komposita

- Ein klassisches Beispiel aus der maschinellen Übersetzung (Systran, um 1980)
  - Barbarei
  - > nightclub nightclub egg
  - Bar|bar|ei
- Ein Beispiel aus der Rechtschreibkonversion (Corigo, um 2000)
  - Hufeisenniere
  - > Hufeisennniere
  - Huf|ei|senn|niere

# Korrektheit und Abdeckung

- Abdeckung und Korrektheit allein sind für sich genommen keine guten Bewertungskriterien:
  - Man kann Korrektheit billig auf Kosten der Abdeckung erreichen und umgekehrt.
  - Ziel: Zuverlässigkeit bei gleichzeitig großer Abdeckung
- Flexionsmorphologie: Unproblematisch (wenn Lexikon mit Flexionsklassen verfügbar ist)
- Kompositazerlegung: **Übergenerierung** ist ein massives Problem
  - kann durch Zusatzmechanismen behoben werden (z.B. Blockierungslisten)
- Derivationsmorphologie: Neigung zur Übergenerierung (Semiproduktivität)
  - Korrekte Ableitungen werden normalerweise als Lemmata gelistet

# Morphologie und Syntax

- Gegenstand der **Morphologie** ist die **Struktur des Wortes**: der Aufbau von Wörtern aus Morphemen, den kleinsten funktionalen oder bedeutungstragenden Einheiten der Sprache.
- Gegenstand der **Syntax** ist die **Struktur des Satzes**: der Aufbau von Sätzen aus Wörtern.
- **Morphologie** beschreibt die grammatischen Merkmale von Wörtern, die durch Wortform oder Flexionsmorpheme kodiert werden.
- **Syntax** beschreibt die Interaktion der grammatischen Merkmale unterschiedlicher Wörter im Satz.

# Eigenschaften der syntaktischen Struktur [1]

- Er hat die Übungen gemacht.
- Der Student hat die Übungen gemacht.
- Der interessierte Student hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student im ersten Semester hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student im ersten Semester, der im Hauptfach Informatik studiert, hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student im ersten Semester, der im Hauptfach, für das er sich nach langer Überlegung entschieden hat, Informatik studiert, hat die Übungen gemacht.

# Beispiele aus der juristischen Praxis

- "Der für die Werkstoffabholung auf der Annahme von drei An- und Abfahrten mit LKW, die Wertstoffe umfüllen, und zwei An- und Abfahrten eines LKW, der zuerst die volle Schrottmulde abholt und diese nach Leerung wiederab liefert, errechnete Beurteilungspegel..."
- "Bei der Umsetzung der Vorgaben der Gerichte für eine verfassungskonforme Regelung der Überführung von Ansprüchen und Anwartschaften aus den Zusatz- und Sonderversorgungssystemen der ehemaligen DDR..."

## Eigenschaften der syntaktischen Struktur [2]

*Peter hat der Dozentin das Übungsblatt heute ins Büro gebracht.*

*Das Übungsblatt hat Peter der Dozentin heute ins Büro gebracht.*

*Der Dozentin hat Peter heute das Übungsblatt ins Büro gebracht.*

*Ins Büro hat heute Peter der Dozentin das Übungsblatt gebracht.*

*Heute hat Peter das Übungsblatt der Dozentin ins Büro gebracht.*

*?Ins Büro hat das Übungsblatt der Dozentin Peter heute gebracht.*

*\* Ins Büro heute Peter das Übungsblatt hat gebracht der Dozentin.*

*\* Ins heute Büro der Peter Dozentin das hat Übungsblatt gebracht.*

## Eigenschaften der syntaktischen Struktur [3]

- Wie finden Sie stattdessen das angehängte Bild?  
Das ist ein Foto, das im Rahmen des TALK-Projektes entstanden ist, uns gehört, und von BMW schon freigegeben war. Außerdem vermittelt es besser den Bezug zur Forschung.

## Eigenschaften der syntaktischen Struktur [3]

- Wie finden Sie stattdessen **die** angehängten Bilder? Das **sind** Fotos, **die** im Rahmen des TALK-Projektes entstanden **sind**, uns gehören, und von BMW schon freigegeben waren. Außerdem vermitteln **sie** besser den Bezug zur Forschung.

# Eigenschaften der syntaktischen Struktur

- Sätze setzen sich aus Satzteilen (**Konstituenten**) zusammen, die wiederum aus einfachen oder ihrerseits komplexen Satzteilen bestehen können. Sätze können deshalb **beliebig lang und beliebig tief geschachtelt** sein.
- Die Syntax natürlicher Sprachen erlaubt **variable Wortstellung**: Wörter und Konstituenten mit der gleichen Funktion können an unterschiedlichen Stellen eines Satzes stehen. Unterschiedliche Sprachen erlauben sehr unterschiedliche Freiheitsgrade.
- Die **grammatischen Eigenschaften** unterschiedlicher Wörter und Konstituenten im Satz **hängen voneinander ab** – zum Teil auch in Fällen, in denen die Wörter und Konstituenten im Satz weit auseinander liegen.

# Fragen zur Repräsentation und Verarbeitung syntaktischer Strukturen

- Natürliche Sprachen sind Sprachen im Sinne der formalen Definition:
  - Wörter sind die Symbole
  - Das Lexikon ist das "Alphabet" ( $\Sigma$ )
  - Korrekte Sätze sind "Worte" über dem Alphabet
  - Die Menge der korrekten Sätze definiert die Sprache  $L \subseteq \Sigma^*$
- Können natürliche Sprachen mit endlichen Automaten beschrieben werden? Gibt es also für eine Sprache  $L$  einen Automaten  $A$  mit  $L(A) = L$ ? Anders gefragt: Sind natürliche Sprachen durch einen regulären Ausdruck darstellbar, sind sie **regulär**?
- Kann eventuell jede denkbare Sprache mit einem endlichen Automaten beschrieben werden?
- Die Antwort ist **Nein**: Es gibt Sprachen, die sich nicht mit endlichen Automaten beschreiben lassen
- ... und zwar sehr einfache Sprachen.

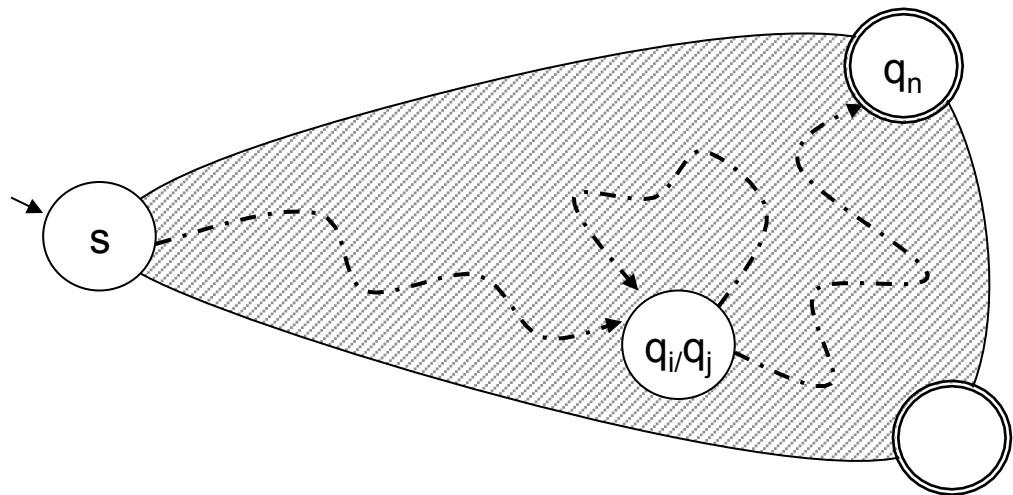
## $a^n b^n$ und endliche Automaten

Um Zugehörigkeit zu  $a^n b^n$  zu erkennen, müsste sich der Automat beliebig lange Ketten von a's merken können, weil er die Information anschließend beim Abarbeiten von b's braucht.

Endliche Automaten haben eine fundamentale Einschränkung: Ihr „Gedächtnis“ ist endlich, durch die Anzahl ihrer Zustände beschränkt. Ein Automat mit k Zuständen kann sich nur an einen beschränkten Kontext „erinnern“, nämlich maximal die k voraufgegangenen Symbole. (Anders ausgedrückt: Er kann nur bis k zählen.)

Ein endlicher Automat kann deshalb nur solche Sprachen erkennen, bei denen die Zulässigkeit eines Symbols in einer Zeichenfolge auf der Grundlage eines Vorkontextes von begrenzter Länge entschieden werden kann.

# Beschränkungen endlicher Automaten



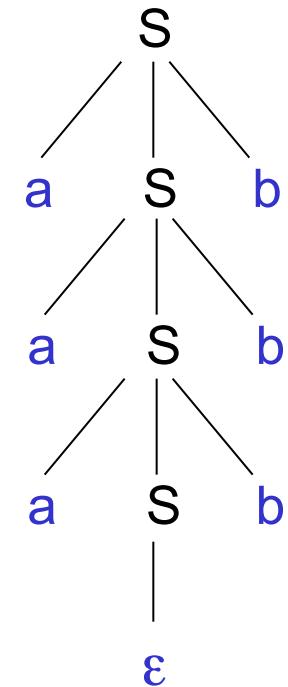
“Pumping Lemma”

# Kontextfreie Grammatik: Ein neuer Formalismus

- Kontextfreie Grammatiken („KFG“, „CFG“) beschreiben Sprachen mithilfe von Ersetzungsregeln („rewrite rules“, Produktionen) der Form  $A \rightarrow w$ 
  - Beispiel:  $S \rightarrow aSb, S \rightarrow \epsilon$  beschreibt  $L = a^n b^n$
- $A \rightarrow u$  ist zu lesen als: Ein Vorkommen von A in einer Symbolfolge/ einem Wort kann durch u ersetzt werden
  - Beispiel:  $aaSbb$  wird zu  $aaaSbbb$  oder zu  $aa\epsilon bb = aabb$
- Eine solche Ersetzung ist ein zulässiger Ableitungsschritt. Wir schreiben:  $aaSbb \Rightarrow aaaSbbb$  bzw.  $aaSbb \Rightarrow aabb$ .
- Um ein Wort über der Sprache  $\{a, b\}$  abzuleiten, beginnen wir mit S (dem „Startsymbol“).
- Wir wenden Ersetzungsregeln an, bis ein Wort w entsteht, das nur noch a's und b's enthält („Terminalsymbole“).
  - Beispiel:  $S \Rightarrow aSb \Rightarrow aaSbb \Rightarrow aaaSbbb \Rightarrow aaabbb$
- Wir zeigen damit, dass w durch die Regeln der Grammatik aus S ableitbar ist: w ein Wort der durch die Grammatik beschriebenen (erzeugten) Sprache L.

# Kontextfreie Grammatiken

- Die Ableitung  
 $S \Rightarrow aSb \Rightarrow aaSbb \Rightarrow aaaSbbb \Rightarrow aaabbb$   
kann alternativ durch eine Ableitungsbaum dargestellt werden.
- Die Wurzel des Baumes ist das Startsymbol.
- Die Blätter des Baums ergeben, von links nach rechts gelesen und aneinandergehängt, das abgeleitete Wort.
- Alternative Schreibweise:  
 $[_S a[_S a[_S a[_S \epsilon ] b] b] b]$



# Kontextfreie Grammatik: Definitionen

$G = \langle V, \Sigma, P, S \rangle$ , wobei

- $V$  nicht-leere Menge von Symbolen
- $\Sigma \subseteq V$  nicht-leere Menge von **Terminalsymbolen**
- $P \subseteq (V - \Sigma) \times V^*$  nicht-leere Menge von **Produktionsregeln**
- $S \in V - \Sigma$  das **Startsymbol**

Die Beispielgrammatik für  $L = a^n b^n$  in formaler Notation:

- $G_1 = \langle \{a, b, S\}, \{a, b\}, \{\langle S, aSb \rangle, \langle S, \varepsilon \rangle\}, S \rangle$
- Für  $\langle A, \alpha \rangle \in P$  schreibt man üblicherweise  $A \rightarrow \alpha$ .

# Kontextfreie Grammatik: Definitionen

- Wenn  $A \rightarrow \alpha$  Produktion,  $w = uAv$  und  $w' = u\alpha v$ , so ist  $w'$  aus  $w$  **in einem Schritt ableitbar**:  $w \Rightarrow w'$
- $w'$  ist aus  $w$  **ableitbar**:  $w \Rightarrow^* w'$  gdw. es eine Folge von Ableitungsschritten gibt, die mit  $w$  beginnt und mit  $w'$  endet.
- Die durch  $G$  **erzeugte Sprache**  $L(G)$  ist die Menge aller Worte über  $\Sigma^*$ , die aus  $S$  ableitbar sind:  $L(G) = \{w \in \Sigma^* \mid S \Rightarrow^* w\}$
- Sprachen, die durch kontextfreie Grammatiken erzeugt werden, heißen **kontextfreie Sprachen**.

# Kontextfreie Grammatik und natürliche Sprache

- Er hat die Übungen gemacht.
- Der Student hat die Übungen gemacht.
- Der interessierte Student hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student im ersten Semester hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student im ersten Semester, der im Hauptfach Informatik studiert, hat die Übungen gemacht.
- Der an computerlinguistischen Fragestellungen interessierte Student im ersten Semester, der im Hauptfach, für das er sich nach langer Überlegung entschieden hat, Informatik studiert, hat die Übungen gemacht.

# Kontextfreie Grammatik und natürliche Sprache

- "Der für die Werkstoffabholung auf der Annahme von drei An- und Abfahrten mit LKW, die Wertstoffe umfüllen, und zwei An- und Abfahrten eines LKW, der zuerst die volle Schrottmulde abholt und diese nach Leerung wiederab liefert, errechnete Beurteilungspegel..."

# Eine erste kontextfreie Grammatik für deutsche Sätze

$G1 = \langle V, \Sigma, P, S \rangle$  mit

$$V = \{S, SRel, NP, VI, VT, N, Det, RPro\} \cup \Sigma$$

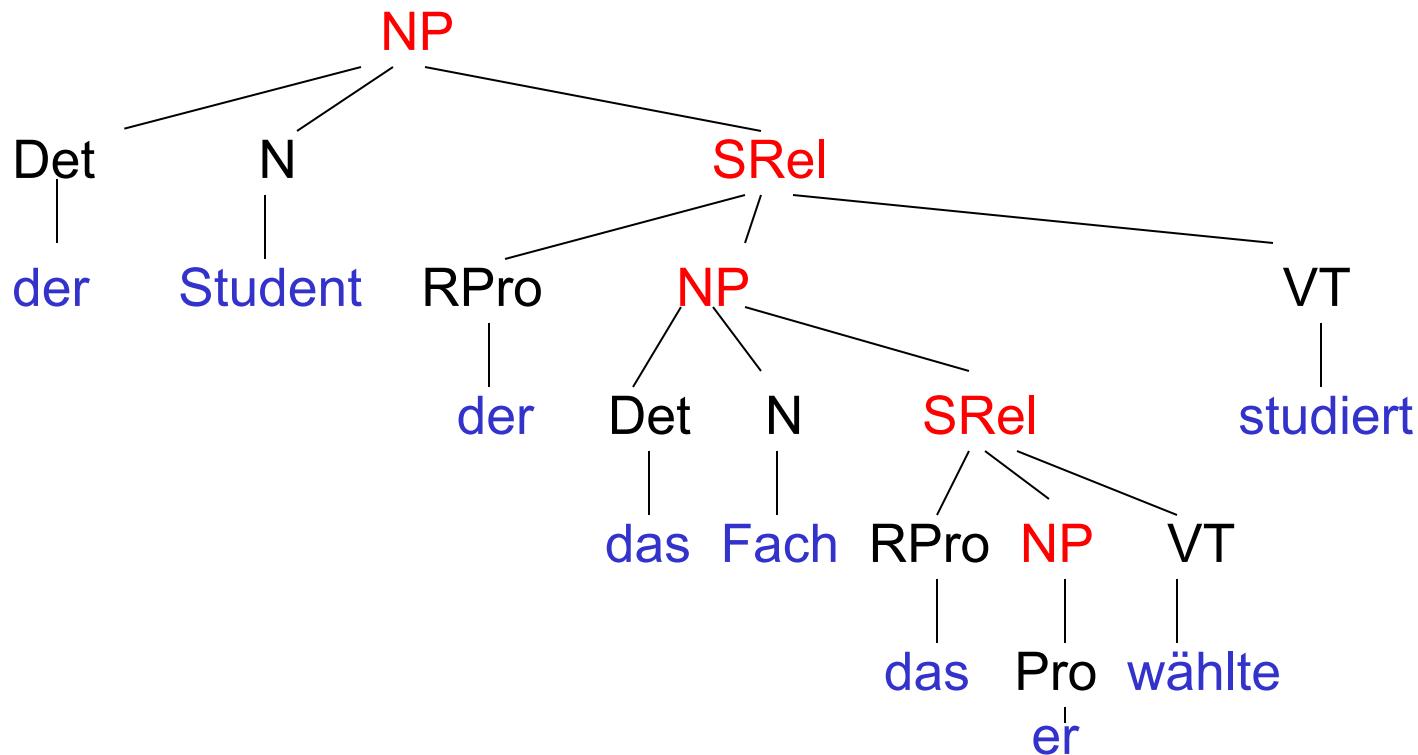
$$\Sigma = \{\textit{schläft}, \textit{arbeitet}, \textit{studiert}, \textit{wählte}, \textit{Student}, \textit{Fach}, \textit{der}, \textit{das}, \textit{er}\}$$

$$\begin{array}{ll} P = & S \rightarrow NP\ VI \\ & S \rightarrow NP\ VT\ NP \\ & SRel \rightarrow RPro\ NP\ VT \\ & SRel \rightarrow RPro\ VI \\ & \\ & NP \rightarrow Det\ N \\ & NP \rightarrow Det\ N\ SRel \\ & NP \rightarrow Pro \end{array}$$

$$\begin{array}{ll} VI \rightarrow \textit{schläft} & N \rightarrow \textit{Student} \\ VI \rightarrow \textit{arbeitet} & N \rightarrow \textit{Fach} \\ VT \rightarrow \textit{studiert} & RPro \rightarrow \textit{der} \\ VT \rightarrow \textit{wählte} & RPro \rightarrow \textit{das} \\ Det \rightarrow \textit{der} & Det \rightarrow \textit{das} \\ Pro \rightarrow \textit{er} & Pro \rightarrow \textit{sie} \end{array}$$

# Geschachtelte Strukturen in natürlicher Sprache

[<sub>NP</sub> der an computerlinguistischen Fragestellungen interessierte Student im ersten Semester, [<sub>SRel</sub> der [<sub>NP</sub> das Fach, [<sub>SRel</sub> das [<sub>NP</sub> er ] nach langer Überlegung gewählt hat ]], eifrig studiert] ]



# Eine kontextfreie Grammatik für deutsche Sätze

Notationskonventionen:

- Alternative Elemente können durch „|“ zusammengefasst werden
- Optionale Elemente können durch runde Klammern notiert werden.

Kompaktere Notation der Grammatik:

$S \rightarrow NP\ VI$

$S \rightarrow NP\ VT\ NP$

$SRel \rightarrow RPro\ VI$

$SRel \rightarrow RPro\ NP\ VT$

$NP \rightarrow Det\ N\ (SRel)$

$NP \rightarrow Pro$

$VI \rightarrow \textit{schläft} | \textit{arbeitet}$

$VT \rightarrow \textit{wählte} | \textit{studiert}$

$N \rightarrow \textit{Student} | \textit{Fach}$

$RPro \rightarrow \textit{der} | \textit{das}$

$Det \rightarrow \textit{der} | \textit{das}$

$Pro \rightarrow \textit{er} | \textit{sie}$

# Kontextfreie Sprachen und endliche Automaten

- Kontextfreie Sprachen sind eine echte Obermenge der Sprachen, die von endlichen Automaten definiert werden („reguläre Sprachen“):
  - Es gibt kontextfreie Sprachen, die nicht regulär sind.
  - Jede reguläre Sprache kann von einer CFG erzeugt werden.
- Endliche Automaten verwenden **Iteration**: Der Automat läuft beliebig oft durch Schleifen und arbeitet dabei Wiederholungen gleicher Symbolfolgen ab.
- Kontextfreie Grammatiken verwenden **Rekursion**. Produktionsregeln verwenden in der Definition eines Ausdruckstyps den Ausdruckstyp selbst: Nicht-Terminale Symbole tauchen auf der linken und der rechten Seite von Regeln auf. Die Regel  $S \rightarrow aSb$  besagt, dass ein Ausdruck, der mit einem a beginnt, mit einem b endet und dazwischen einen korrekten Ausdruck des Typs S enthält, ebenfalls ein korrekter Ausdruck vom Typ S ist.
- Rekursive Regeln erlauben die tiefe Schachtelung von Strukturen, und sie ermöglichen, dass eine Regel Elemente in Beziehung setzt, die in der Kette beliebig weit voneinander entfernt sind.

# Kontextfreie Sprachen und natürliche Sprachen

- Kontextfreie Grammatiken sind ein Standardformalismus zur Beschreibung der Grammatik **natürlicher Sprachen**.
- Kontextfreie Grammatiken bilden den Standard-Formalismus zur syntaktischen Beschreibung von **formalen Sprachen** (Logik, Arithmetik, Programmiersprachen).
- Ein alternatives, der CGF ähnliches Format zur Beschreibung kontextfreier Sprachen ist **BNF** (die „Backus-Naur-Form“).