

Einführung in die Computerlinguistik

Statistische Modellierung

WS 2014/2015
Vera Demberg

Fragebogenaktion Bachelor-StudentInnen

<http://www.coli.uni-saarland.de/bsc/page.php?id=fragebogen>

Klausuranmeldung nicht vergessen!

Mehrdeutigkeit

Strukturelle Mehrdeutigkeit:

Peter sieht den Mann mit dem Teleskop (Anbindungsambiguität)

Zwei Fremdsprachen spricht jeder Linguist (Skopusambiguität)

Referenzielle Mehrdeutigkeit:

er, sie, es, dort, damals, der Präsident, die Vorlesung

Hans mag seinen Hund, obwohl er ihn manchmal beißt

Lexikalische Mehrdeutigkeit:

Bank, Absatz, Baum

Wortart-Mehrdeutigkeit

laut

finites Verb, Adjektiv

Laut

Gattungssubstantiv (2x), finites Verb, Adjektiv

zu

Adverb, Präposition, Gradpartikel, Verbpartikel

der

Artikel, Demonstrativpronomen, Relativpronomen

Wortart-Disambiguierung

- Einführung von Wortart-Alternativen im Lexikon (alternative lexikalische Ersetzungsregeln bzw. alternative Merkmalsstrukturen).
- Die Grammatik filtert syntaktisch unzulässige Wortartvarianten heraus.
- Wo liegt also das Problem?
- In normalen Texten (z.B. Zeitungstexten) kommen extrem viele "neue" Wörter vor, für die es gar keine Wortartinformation gibt.
- Für viele Sprachen/ Fach- und Sondersprachen gibt es keine Grammatiken; für viele Anwendungen sind große Grammatiken zu langsam. – Es wäre gut, trotzdem Wortartinformation zu haben.

Wortart-Tagging

- Wortartinformation lässt sich glücklicherweise auf der Grundlage „flacher“ linguistischer Information (d.h., ohne syntaktische Analyse) mit großer Sicherheit bereitstellen.
- Wortartinformation wird durch „Wortart-Tagger“ oder „POS-Tagger“ bereitgestellt (POS für „part of speech“, engl. „tag“ ist die Marke/ das Etikett).
- Wortart-Tagger sind heute gut funktionierende Standardwerkzeuge der Sprachverarbeitung, genau wie Morphologie-Systeme. – Sie funktionieren allerdings grundsätzlich anders.

Beispielaufgabe: Adjektiverkennung

- Wortart-Tagger für das Deutsche müssen aus einer von ca. 50 Kategorien wählen, anders ausgedrückt: Sie müssen Textwörter einer von 50 Klassen zuweisen.
- Wir betrachten hier eine einfachere Teilaufgabe: Die Beantwortung der Frage, ob es sich bei einem Vorkommen eines Wortes in einem Text um ein Adjektiv handelt (also eine binäre Klassifikationsaufgabe).

Informative Merkmale

- Woran erkenne ich, dass ein Wortvorkommen ein Adjektiv ist – ohne Lexikon und volle syntaktische Analyse?
die laute Musik
das allativistische Übungsblatt
- Beispiele:
 - Kleinschreibung des aktuellen Wortes w_i
 - Großschreibung des Folgewortes w_{i+1}
 - Vorgängerwort w_{i-1} ist Artikel
 - w_i hat Komparativ-/ Superlativendung
 - w_i hat adjektivspezifisches Derivations-Suffix (-ig, -lich, -isch, -sam)
 - w_{i-1} ist Gradpartikel (sehr, besonders, ziemlich)

Regelbasierte Wortartzuweisung

- Ein System von wenn-dann-Regeln:
Wenn $\langle \text{Merkmall} \rangle, \dots, \langle \text{Merkmaln} \rangle$ vorliegen, dann
weise $\langle \text{Wortart} \rangle$ zu.

Regelbasiertes Modell

w_i klein & w_{i+1} groß & w_{i-1} Artikel → ADJA

Text: Vor dem kleinen Haus steht ein großer Baum

```
graph TD; Vor[N] --> NADJA1[NADJA]; dem[N] --> NADJA2[NADJA]; kleinen[N] --> ADJA1[ADJA]; Haus[N] --> NADJA3[NADJA]; steht[N] --> NADJA4[NADJA]; ein[N] --> NADJA5[NADJA]; großer[N] --> ADJA2[ADJA]; Baum[N] --> NADJA6[NADJA];
```

Vollständigkeitsproblem

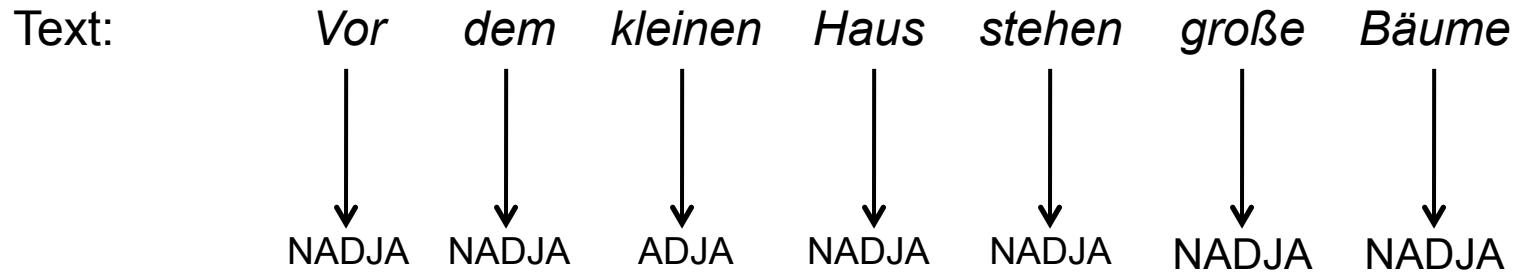
w_i klein & w_{i+1} groß & w_{i-1} Artikel \rightarrow ADJ

Text: Vor dem kleinen Haus stehen große Bäume

NADJA NADJA ADJA NADJA NADJA **NADJA** NADJA

Korrigiertes Modell

w_i klein & w_{i+1} groß → ADJA



Korrektheitsproblem

w_i klein & w_{i+1} groß → ADJA

Text: Vor dem kleinen Haus stehen Bäume

```
graph LR; Vor[NADJA] --> Vor; dem[NADJA] --> dem; kleinen[ADJA] --> kleinen; Haus[NADJA] --> Haus; stehen[ADJA] --> stehen; Bäume[NADJA] --> Bäume;
```

Regelbasierte und statistische Modellierung

- Regelsysteme, die die Abhangigkeit der Wortart von Merkmalsmustern korrekt und vollstandig erfassen sollen, werden schnell sehr komplex und aufwandig zu formulieren.
- Alternative: Wir bauen Systeme, die den Zusammenhang von Merkmalsmustern und Wortarten aus **Textkorpora** lernen!
(Singular: **das Korpus**)

Ein ganz kleiner Korpus-Ausschnitt

Text:

Vor dem kleinen Haus steht ein großer Baum

Ein ganz kleiner Korpus-Ausschnitt

Text:

Vor dem kleinen Haus steht ein großer Baum

Manuelle
Annotation

NADJA

NADJA

ADJA

NADJA

NADJA

NADJA

ADJA

NADJA

Ein ganz kleiner Korpus-Ausschnitt

Text:

Vor dem kleinen Haus steht ein großer Baum

Merkmale:

w_i groß

w_{i+1} groß

w_{i-1} Artikel

Manuelle
Annotation

NADJA NADJA ADJA NADJA NADJA NADJA ADJA NADJA

Ein ganz kleiner Korpus-Ausschnitt

Text:

Vor dem kleinen Haus steht ein großer Baum

Merkmalsextraktion:

w_i groß	+	-	-	+	-	-	-	+
w_{i+1} groß	-	-	+	-	-	-	+	-
w_{i-1} Artikel	-	-	+	-	-	-	+	-
Manuelle Annotation	NADJA	NADJA	ADJA	NADJA	NADJA	NADJA	ADJA	NADJA

Statistische Modellierung

- **Manuelle Korpusannotation:**
 - Wir wählen ein Textkorpus und nehmen eine **manuelle Annotation** mit den Zielklassen (in unserem Fall $\in \{\text{ADJA}, \text{NADJA}\}$) vor.
- **Merkmalspezifikation:**
 - Wir spezifizieren eine Menge von geeigneten **Merkmälern** („features“) mit zugehörigen Wertebereichen.
 - In unserem Fall (bisher) 3 Merkmale mit jeweils binärem Wertbereich: $\{+,-\}$ oder $\{0,1\}$: **binäre** oder **Boole'sche Merkmale**

Geeignete Merkmale sind

 - informativ in Bezug auf die **Klassifikationsaufgabe**
 - einfach zugänglich: direkt ablesbar oder ohne Aufwand automatisch zu ermitteln
- **Automatische Merkmalsextraktion:**
 - Wir stellen ein Verfahren bereit, das für jede **Instanz** (hier: für jedes Textwort) automatisch das zugehörige **Merkmalsmuster** bestimmt.

Statistische Modellierung

- Wir „trainieren“ ein maschinelles Lernsystem auf dem Korpus („Trainingskorpus“).
- Das System „lernt“ ein statistisches Modell, das neuen, nicht annotierten Instanzen (auf der Grundlage des Merkmalsmusters) die wahrscheinlichste Klasse zuweisen kann.
- Das einfachste Verfahren für das Erlernen eines Klassifikationsmodells besteht im Auszählen der Häufigkeit, mit der Klassen im Zusammenhang mit bestimmten Merkmalsmustern auftreten.

Beispiel: Adjektive im Wahrig-Korpus

- Frequenzen in einem kleinen Teilkorpus:

n groß	-	-	-	-	+	+	+	+
n+1 groß	-	-	+	+	-	-	+	+
n-1 Art.	-	+	-	+	-	+	-	+
ADJA	31	12	140	84	1	1	8	2
NADJA	1827	58	738	18	730	249	98	3

- Relative Frequenz als geschätzte Wahrscheinlichkeit:
Ein einfaches statistisches Modell

n groß	-	-	-	-	+	+	+	+
n+1 groß	-	-	+	+	-	-	+	+
n-1 Art.	-	+	-	+	-	+	-	+
ADJA	0,017	0,171	0,159	0,824	0,001	0,004	0,075	0,400
NADJA	0,983	0,829	0,841	0,176	0,999	0,996	0,925	0,600

Wahrscheinlichkeit und Frequenz

- Wir nehmen die relative Häufigkeit, mit der eine Klasse k im Kontext eines Merkmalsmusters e auftritt, als Schätzung der bedingten Wahrscheinlichkeit, dass k vorliegt, gegeben e .
- Beispiel: ADJA kommt mit dem Merkmalsmuster $\langle -, +, + \rangle$, also "n klein, n+1 groß, n-1 Artikel" 738mal (von insgesamt 878) vor; die relative Frequenz ist $\approx 0,824$, wir nehmen also die Wahrscheinlichkeit, dass in dieser Konstellation ein Adjektiv vorliegt, ebenfalls mit 0,824, also 82,4% an.

Etwas Terminologie zur Wahrscheinlichkeitstheorie

- **Beobachtung:**
 - Einzelvorkommen oder Instanz
 - Beispiel: ein Wurf mit zwei Würfeln, ein Textwort
- **Ereignis:**
 - Klasse von Beobachtungen mit gleichen Merkmalen
 - Beispiele: "eine 7 würfeln", "ein groß geschriebenes Wort"
 - Die unterschiedlichen Merkmalsmuster spezifizieren „**Ereignisse**“ im Sinne der Wahrscheinlichkeitstheorie. Die Merkmale in unserem Beispiel spannen den „**Ereignisraum**“ auf (hier mit $2 \cdot 2 \cdot 2 = 8$ Elementen).
- **Wahrscheinlichkeit** eines Ereignisses: $P(e) \in [0, 1]$
- **Gemeinsame Wahrscheinlichkeit**, Wahrscheinlichkeit, dass zwei Ereignisse gleichzeitig vorliegen: $P(e, e')$
- **Bedingte Wahrscheinlichkeit** (e gegeben e'):

$$P(e | e') = \frac{P(e, e')}{P(e')}$$

Wahrscheinlichkeit und Frequenz

- Wir sind an der Wahrscheinlichkeit einer Klasse k , gegeben ein Merkmalsmuster f , interessiert:

$$P(k | f) = \frac{P(k, f)}{P(f)}$$

- Wir schätzen die Wahrscheinlichkeiten über Korpusfrequenzen:

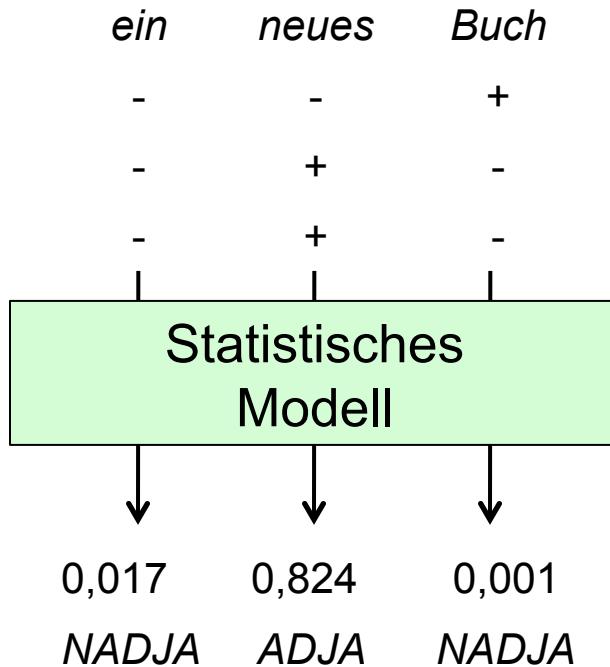
$$P(k | f) = \frac{P(k, f)}{P(f)} \approx \frac{Fr(k, f)}{Fr(f)}$$

- Beispiel:

$$P(ADJA | \langle -, +, + \rangle) \approx \frac{Fr(ADJA, \langle -, +, + \rangle)}{Fr(\langle -, +, + \rangle)} = \frac{84}{102} = 0,824$$

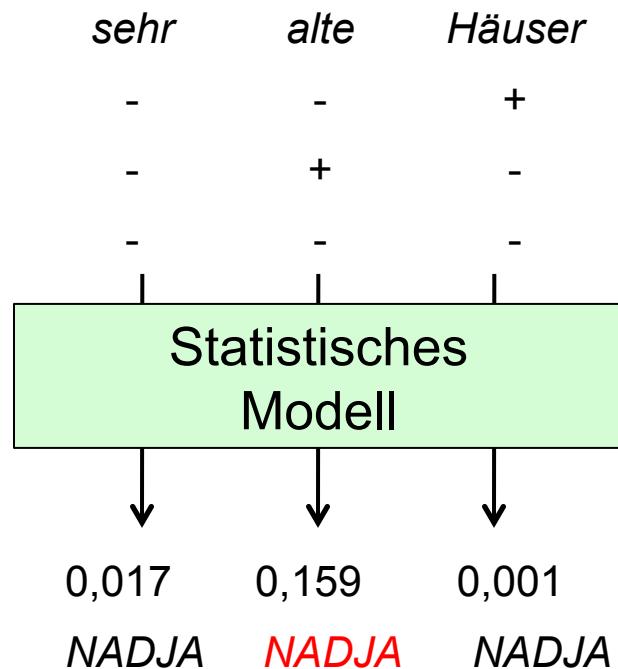
Anwendung des statistischen Modells

- Neuer Text: Merkmalsextraktion; auf der Grundlage der Merkmale Bestimmung (eigentlich "Ablesen") der geschätzten Wahrscheinlichkeit.
- Da wir an der Zuweisung der im Kontext angemessenen Wortart interessiert sind, verwenden wir das Modell als **Klassifikator**: Es weist die jeweils aufgrund des Merkmalsmusters wahrscheinlichste Klasse zu.
- Wir können die Wahrscheinlichkeitsinformation zusätzlich verwenden, z.B. als "**Konfidenz**" (Klassifikation wird nur bei einer Wahrscheinlichkeit $\geq 0,8$ zugewiesen) oder zur Parsersteuerung (Bottom-Up-Parser probiert die Wortart-Alternativen in der Reihenfolge ihrer Wahrscheinlichkeit aus).



Klassifikationsfehler

- Auch statistische Modelle machen Korrektheits- und Vollständigkeitsfehler.
- Man kann die Modelle verbessern, indem man die Merkmalsinformation verfeinert, beispielsweise durch Einführung eines Merkmals "Vorgängerwort ist Gradpartikel".
- Das Verfahren stößt allerdings an Grenzen.



Größe des Merkmalsraums

- Wieso verwendet man nicht alle Merkmale, die irgendwie erfolgversprechend sind?
- Ereignisraum:
 - Wir haben im Beispiel 3 binäre Merkmale verwendet, es gibt also $2*2*2=8$ Ereignisse.
 - Wenn wir 10 binäre Merkmale verwenden, haben wir bereits über 1000 Ereignisse.
- Die Instanzen im Trainingskorpus verteilen sich auf die einzelnen Ereignisse (Merkmalsmuster).
 - Das Trainingskorpus muss deutlich größer sein als der Ereignisraum. Ansonsten treten viele Merkmalsmuster nur wenige Male auf, oder auch gar nicht („ungesehene Ereignisse“): Das Modell kann im ersten Fall nur sehr unzuverlässige Schätzungen machen, im letzteren Fall gar keine.
 - Dies ist das sogenannte „Sparse-Data“-Problem.

Sparse-Data-Problem

- Je mehr Merkmale, umso besser ist grundsätzlich die Datenlage für die Entscheidung, aber:
- Je mehr Merkmale, auf desto mehr Ereignisse verteilen sich die Trainingsdaten. Die Wahrscheinlichkeitsschätzung wird ungenau oder sogar unmöglich.
- Faustregel für die Wahl einer geeigneten Merkmalsmenge:
 - Wenige gute (aussagekräftige) Merkmale sind besser als viele mittelmäßige.
 - Merkmale mit weniger möglichen Werten sind grundsätzlich vorzuziehen.

Evaluation

- Jedes Modell muss evaluiert werden: Stimmt es mit der Realität, die es beschreiben soll, mit der Funktion, die es ausführen soll, überein?
- Dies gilt für wissensbasierte und statistische Modelle grundsätzlich in gleicher Weise.
- Da statistische Verfahren typischerweise auf Probleme angewandt werden, die keine vollständige Korrektheit erreichen können (z.B. Disambiguierung in allen Spielarten), ist es hier besonders wichtig.

Evaluation

- Annotation eines „Goldstandard“: Testkorpus mit der relevanten Zielinformation (z.B. Wortart)
 - Um subjektive Varianz auszuschließen, wird durch mehrere Personen unabhängig annotiert und die Übereinstimmung („[Inter-
Annotator-Agreement](#)“: IAA) gemessen.
 - Testkorpus und Trainingskorpus müssen disjunkt sein, um Effekte aus individuellen Besonderheiten eines Korpus auszuschließen („overfitting“).
- Automatische Annotation des Testkorpus mit statistischem Modell/ Klassifikator
- Messung der Performanz durch Vergleich von automatischer Annotation mit Goldstandard

Akkuratheit

- Akkuratheit (engl. *accuracy*) ist das einfachste Maß:

Akkuratheit = korrekt klassifizierte Instanzen/alle Instanzen

- Fehlerrate (engl. *error rate*) ist der Komplementärbegriff zu Akkuratheit:

Fehlerrate = $1 - \text{Akkuratheit}$

- Das Akkuratheitsmaß verdeckt oft tatsächlich relevante Eigenschaften eines Modells.

Konfusionsmatrix

- Grundlage für eine feinere Evaluation des Klassifikators ist die Konfusionsmatrix.
- Konfusionsmatrix (Verwechslungstabelle) für binäre Klassifikation:

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	ok	falsch
Klassifiziert als NADJA	falsch	ok

Konfusionsmatrix

- Fehlertypen für ADJA-Klassifikation:

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	ok	Korrektheitsfehler
Klassifiziert als NADJA	Vollständigkeitsfehler	ok

Konfusionsmatrix

- Fehlertypen für ADJA-Klassifikation:

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	true positive	false positive
Klassifiziert als NADJA	false negative	true negative

Konfusionsmatrix

- (Fiktives) Beispiel:

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	20	80
Klassifiziert als NADJA	20	880

- Von insgesamt 1000 Fällen sind 900 korrekt (Wahre Positive und wahre Negative): Akkurateit ist also 90%, Fehlerrate 10%.
- Tatsächlich ist die Adjektiverkennung miserabel: von fünf als ADJA klassifizierten Instanzen ist nur eine korrekt.
- Wir bestimmen **Recall** und **Präzision/ Precision** als klassenspezifische Maße, die Vollständigkeits- und Korrektheitsfehler (für eine gegebene Klasse) separat messen.

Recall

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	True positive	False positive
Klassifiziert als NADJA	False negative	True negative

- Welcher Anteil der echten X wurde tatsächlich gefunden (als X klassifiziert)?

Recall = True positives/(True positives + False negatives)

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	20	80
Klassifiziert als NADJA	20	880

Recall für ADJA = 20/(20+20) = 0,5

Präzision

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	True positive	False positive
Klassifiziert als NADJA	False negative	True negative

- Welcher Anteil der als X klassifizierten Instanzen ist tatsächlich ein X?

Precision = True positives/(True positives + False positives)

	Echtes ADJA	Echtes NADJA
Klassifiziert als ADJA	20	80
Klassifiziert als NADJA	20	880

Precision für ADJA = $20/(20+80) = 0,2$

Präzision und Recall

- Präzision und Recall sind im allgemeinen nur zusammen aussagekräftig
 - Hohe Präzision, hoher Recall: gutes Modell
 - Niedrige Präzision, niedriger Recall: schlechtes Modell
 - Hohe Präzision, niedriger Recall: „Vorsichtiges“ Modell
 - Findet nicht alle Instanzen von X
 - Klassifiziert kaum Nicht-Xe als X
 - Niedrige Präzision, hoher Recall: „Mutiges“ Modell
 - Findet fast alle Instanzen von X
 - Klassifiziert viele nicht-Xe fehlerhaft als X
 - Extremfälle
 - Modell klassifiziert alles als X: Recall 100%, Precision niedrig
 - Modell klassifiziert nichts als X: Recall 0%, Precision nicht definiert

F-Score

- Der „F-Score“ ist ein Maß für die „Gesamtgüte“ der Klassifikation, in das Precision und Recall eingehen.

$$F = \frac{2PR}{P + R}$$

- F-Score für die Klasse ADJA im Beispiel:

$$F = \frac{2 * 0,2 * 0,5}{0,2 + 0,5} = 0,29$$

Noch einmal: Wortart-Tagging

- Standard Wortart-Tagger arbeiten mit ca. 50 Klassen und haben dabei eine Akkuratheit von deutlich über 99%.
- Sie gehen dabei natürlich etwas anders vor, als hier demonstriert: Sie verwenden maschinelle Lernverfahren, die nicht nur die besten POS-Tags für die einzelnen Wörter im Satz, sondern die beste POS-Kette für einen ganzen Satz zu bestimmen versuchen.
- Beispiel: Auch wenn in „*I made her duck*“ die wahrscheinlichste Wortart für *her* Personalpronomen und für *duck* Gattungssubstantiv ist, ist die Kombination der Wortarten sehr unwahrscheinlich.
- Die Methode, Wahrscheinlichkeiten für Sequenzen zu bestimmen, ist auch in der Verarbeitung gesprochener Sprache wichtig („HMMs: „Hidden Markov Models“)